

Cloud Analytics y Data Lake

Procesamiento y exploración de datos

Housing utilizando Python

Nombre: Ali Vega

Curso: Big Data y Cloud Analytics

Fecha: Mayo 2026

Configuración de un Data Lake simple

Creación de carpetas para almacenamiento de datos crudos y procesados simulando una estructura básica de Data Lake.



Your Toolbox for Python Projects

Anaconda Cloud

Create a New Project

Create a New Notebook

My Projects

Code Snippets

Manage Code Snippets

Anaconda AI Assistant

Chat-based Python Help

Jupyter M54 Last Checkpoint: 9 minutes ago

File Edit View Run Kernel Settings Help

JupyterLab Python [conda env:base] * Anaconda Toolbox

Procesamiento y exploración de datos Housing utilizando Python

Introducción

En esta práctica se implementa una estructura básica de Data Lake y procesamiento de datos en la nube utilizando Python. Asimismo, se realiza la importación y exploración del dataset Housing mediante técnicas de análisis de datos y procesos ETL básicos.

El objetivo es comprender cómo almacenar, conectar, transformar y analizar información dentro de un entorno de Cloud Analytics, obteniendo métricas y análisis relevantes para la toma de decisiones de negocio.

1. Importación de librerías

Se importan las librerías necesarias para el procesamiento, exploración y visualización de datos.

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

2. Configuración de un Data Lake simple

Para esta práctica se utiliza una estructura simple de almacenamiento de datos mediante carpetas locales, simulando las capas de un Data Lake para almacenamiento de datos crudos y procesados.

```
[2]: import os

os.makedirs("data_lake/raw", exist_ok=True)
os.makedirs("data_lake/processed", exist_ok=True)

print("Estructura Data Lake creada correctamente")

Estructura Data Lake creada correctamente
```

[]:

AI-powered coding, insights and debugging in your notebooks.

To enable the following extensions, create an account or sign in.

Anaconda Assistant 4.18.0

Create Account

Already have an account? [Sign In](#)

For more information, read our [Anaconda Assistant documentation](#).

Configuración de base de datos

Creación de una base de datos SQLite para almacenamiento y procesamiento de información.

Importación del dataset Housing

Carga y visualización inicial del dataset utilizando Python y Pandas.

 **Anaconda Toolbox**   

v4.20.0

 **Anaconda**
Your Toolbox for Python Projects

 **Anaconda Cloud**

Create a New Project

Create a New Notebook

My Projects

 **Code Snippets**

Manage Code Snippets

 **Anaconda AI Assistant**

Chat-based Python Help

 **Jupyter** M54 Last Checkpoint: 17 minutes ago

File Edit View Run Kernel Settings Help

JupyterLab Python [conda env:base] Anaconda Toolbox

1. Importación de librerías

Se importan las librerías necesarias para el procesamiento, exploración y visualización de datos.

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

2. Configuración de un Data Lake simple

Para esta práctica se utiliza una estructura simple de almacenamiento de datos mediante carpetas locales, simulando las capas de un Data Lake para almacenamiento de datos crudos y procesados.

```
[2]: import os

os.makedirs("data_lake/raw", exist_ok=True)
os.makedirs("data_lake/processed", exist_ok=True)

print("Estructura Data Lake creada correctamente")
```

Estructura Data Lake creada correctamente

3. Configuración de base de datos

Se crea una conexión simple utilizando SQLite como base de datos local para simular un entorno de procesamiento en la nube.

```
[3]: import sqlite3

conexion = sqlite3.connect("housing_cloud.db")

print("Base de datos creada correctamente")
```

Base de datos creada correctamente

4. Importación del archivo Housing

Se importa el dataset Housing utilizando Python y Pandas para comenzar el proceso de exploración y análisis.

```
[4]: housing = pd.read_csv(r"C:\Users\alive\Downloads\Analista de datos M54 - kc_house_data.csv")
```

 **Anaconda Assistant**
AI-powered coding, insights and debugging in your notebooks.

To enable the following extensions, create an account or sign in.

 **Anaconda Assistant** 4.18.0

Create Account

Already have an account? [Sign In](#)

 For more information, read our [Anaconda Assistant documentation](#).

KPIs del negocio

Cálculo de métricas principales relacionadas con precio, tamaño y habitaciones de las viviendas.

 **Anaconda Toolbox**   

v4.20.0

 **Anaconda**
Your Toolbox for Python Projects

 **Anaconda Cloud**

Create a New Project 

Create a New Notebook 

My Projects 

 **Code Snippets**

Manage Code Snippets 

 **Anaconda AI Assistant**

Chat-based Python Help 

 **jupyter** M54 Last Checkpoint: 12 minutes ago

File Edit View Run Kernel Settings Help

JupyterLab Python [conda env:base] Anaconda Toolbox

```
[6]: housing.columns

[6]: Index(['id', 'date', 'price', 'bedrooms', 'bathrooms', 'sqft_living',
         'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade',
         'sqft_above', 'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode',
         'lat', 'long', 'sqft_living15', 'sqft_lot15'],
        dtype='object')

[7]: housing = housing.drop_duplicates()

[8]: housing.to_sql(
      "housing",
      conexion,
      if_exists="replace",
      index=False
    )

[8]: 21613
```

7. KPIs del negocio

Se calculan indicadores clave que permiten comprender la magnitud y comportamiento general de las viviendas registradas.

```
[9]: promedio_precio = housing["price"].mean()
     promedio_tamano = housing["sqft_living"].mean()
     promedio_habitaciones = housing["bedrooms"].mean()

     print("Precio promedio:", promedio_precio)
     print("Tamaño promedio:", promedio_tamano)
     print("Habitaciones promedio:", promedio_habitaciones)

Precio promedio: 540088.1417665294
Tamaño promedio: 2079.8997362698374
Habitaciones promedio: 3.37084162309721
```

[]:       

 **Anaconda Assistant**
AI-powered coding, insights and debugging in your notebooks.

To enable the following extensions, create an account or sign in.

 **Anaconda Assistant** 4.18.0

Create Account

Already have an account? [Sign In](#)

 For more information, read our [Anaconda Assistant documentation](#).

29°C Soleado

02:06 p. m. 16/05/2026

Consulta SQL y análisis de precios por código postal

Consulta de precios promedio agrupados por código postal utilizando SQL y Python.



Your Toolbox for Python Projects

Anaconda Cloud

Create a New Project

Create a New Notebook

My Projects

Code Snippets

Manage Code Snippets

Anaconda AI Assistant

Chat-based Python Help

11. Consulta SQL

Se ejecuta una consulta SQL simple sobre la base de datos creada.

```
[13]: consulta = pd.read_sql("""
SELECT
    zipcode,
    AVG(price) AS promedioPrecio
FROM housing
GROUP BY zipcode
ORDER BY promedioPrecio DESC
LIMIT 10
""", conexion)

consulta
```

```
[13]:
```

	zipcode	promedioPrecio
0	98039	2.160607e+06
1	98004	1.355927e+06
2	98040	1.194230e+06
3	98112	1.095499e+06
4	98102	9.012583e+05
5	98109	8.796236e+05
6	98105	8.628252e+05
7	98006	8.596848e+05
8	98119	8.494480e+05
9	98005	8.101649e+05

12. Conclusión

En esta práctica se implementó una estructura básica de Data Lake y procesamiento de datos utilizando Python. También se creó una base de datos para almacenar información del dataset Housing y se realizaron procesos ETL básicos.

Finalmente, se exploró la información mediante KPIs, consultas y análisis adicionales que permiten comprender mejor el comportamiento de las viviendas y generar información útil para el negocio.

AI-powered coding, insights and debugging in your notebooks.

To enable the following extensions, create an account or sign in.

Anaconda Assistant 4.18.0

Create Account

Already have an account? [Sign In](#)

For more information, read our [Anaconda Assistant documentation](#).

Relación entre tamaño y precio de las viviendas

Visualización de la relación entre el tamaño de las viviendas y su valor económico.

 **Anaconda Toolbox**   

Anaconda
Your Toolbox for Python Projects

Anaconda Cloud
Create a New Project
Create a New Notebook
My Projects

Code Snippets
Manage Code Snippets

Anaconda AI Assistant
Chat-based Python Help

 **jupyter** M54 Last Checkpoint: 13 minutes ago

File Edit View Run Kernel Settings Help


JupyterLab Python [conda env:base] Anaconda Toolbox

98119 8.494480e+05
98005 8.101649e+05
Name: price, dtype: float64

10. Análisis 3 – Relación entre tamaño y precio

Se analiza si existe una relación entre el tamaño de la vivienda y su precio.

```
[12]: housing.plot.scatter(  
      x="sqft_living",  
      y="price",  
      figsize=(8,5)  
      )  
      plt.show()
```



```
[ ]: |
```

 **Anaconda Assistant**
AI-powered coding, insights and debugging in your notebooks.

To enable the following extensions, create an account or sign in.

 **Anaconda Assistant** 4.18.0

Create Account

Already have an account? [Sign In](#)

 For more information, read our [Anaconda Assistant documentation](#).

29°C Soleado 02:07 p. m. 16/05/2026

CONCLUSIÓN

Durante esta práctica se implementó una estructura básica de Data Lake y procesamiento de datos utilizando Python. Asimismo, se creó una base de datos para almacenar la información del dataset Housing y se realizaron procesos ETL para transformar y cargar los datos.

Posteriormente, se desarrollaron análisis exploratorios, KPIs y consultas SQL que permitieron comprender el comportamiento de las viviendas, sus precios y características principales. Finalmente, se observó la relación entre el tamaño de las viviendas y su valor, obteniendo información útil para la toma de decisiones dentro de un entorno de Cloud Analytics.