

— PROYECTO FINAL

CLOUD ANALYTICS & HOUSING DATA LAKE

Flujo analítico basado en Data Lake para análisis inmobiliario, generación de KPIs e insights de negocio.



ANALÍTICA
CLOUD



ARQUITECTURA
DATA LAKE



ANÁLISIS
SQL



PYTHON
& ETL



KPIs &
REPORTING



ALI VEGA

ANÁLISIS DE DATOS | CLOUD ANALYTICS | BI



2026



CONTEXTO Y OBJETIVO



PREGUNTA DE NEGOCIO

¿Cómo podemos aprovechar **datos de viviendas** utilizando un flujo de trabajo basado en **Data Lake** para generar **insights estratégicos** y apoyar la toma de decisiones?



OBJETIVO DEL PROYECTO

Simular un entorno de análisis en la nube para procesar, almacenar y analizar datos de vivienda, utilizando herramientas de **ETL**, **SQL** y **Python** para generar **KPIs** y **visualizaciones** que impulsen decisiones de negocio.



IMPACTO ESPERADO

Contar con un flujo analítico robusto que permita entender el comportamiento del mercado inmobiliario y generar insights confiables para decisiones más efectivas y basadas en datos.

OBJETIVOS ESPECÍFICOS



SIMULAR UN DATA LAKE

Estructurar y almacenar datos de vivienda siguiendo principios de Data Lake.



IMPLEMENTAR ETL

Extraer, transformar y cargar datos asegurando calidad e integridad.



REALIZAR ANÁLISIS SQL

Ejecutar consultas analíticas para obtener métricas clave del negocio.



GENERAR KPIs ANALÍTICOS

Calcular indicadores clave que permitan evaluar el comportamiento de los datos.



APOYAR DECISIONES ESTRATÉGICAS

Transformar los datos en información accionable para impulsar decisiones de negocio.

ARQUITECTURA E IMPLEMENTACIÓN DEL FLUJO ANALÍTICO



Este proyecto sigue un flujo analítico basado en arquitectura Data Lake, desde la ingesta y procesamiento de datos hasta la generación de KPIs, análisis y visualizaciones estratégicas.



1 RAW DATA

Ingesta de datos de viviendas desde múltiples fuentes.



2 DATA LAKE

Almacenamiento estructurado y escalable de datos.



3 PYTHON PROCESSING

Limpieza, transformación y preparación de datos.



4 SQLITE STORAGE

Persistencia de datos procesados para análisis eficiente.



5 SQL ANALYTICS

Consultas SQL para extracción de métricas y análisis.



6 KPI & VISUALIZATION

Generación de KPIs e insights visuales.



OBJETIVO

Transformar datos en información accionable para decisiones estratégicas basadas en datos.



ENFOQUE

ETL • SQL • Python
Data Lake • Visualización



BENEFICIO

Insights accionables que impulsan el crecimiento del negocio.



TECNOLOGÍAS CLAVE

Python • SQLite • SQL
Data Lake • Visualización



2026

jupyter M54 Last Checkpoint: 9 minutes ago

File Edit View Run Kernel Settings Help

Trusted

JupyterLab Python [conda env:base] Anaconda Toolbox

Procesamiento y exploración de datos Housing utilizando Python

Introducción

En esta práctica se implementa una estructura básica de Data Lake y procesamiento de datos en la nube utilizando Python. Asimismo, se realiza la importación y exploración del dataset Housing mediante técnicas de análisis de datos y procesos ETL básicos.

El objetivo es comprender cómo almacenar, conectar, transformar y analizar información dentro de un entorno de Cloud Analytics, obteniendo métricas y análisis relevantes para la toma de decisiones de negocio.

1. Importación de librerías

Se importan las librerías necesarias para el procesamiento, exploración y visualización de datos.

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

2. Configuración de un Data Lake simple

Para esta práctica se utiliza una estructura simple de almacenamiento de datos mediante carpetas locales, simulando las capas de un Data Lake para almacenamiento de datos crudos y procesados.

```
[2]: import os

os.makedirs("data_lake/raw", exist_ok=True)
os.makedirs("data_lake/processed", exist_ok=True)

print("Estructura Data Lake creada correctamente")
```

Estructura Data Lake creada correctamente



05

ANÁLISIS SQL Y GENERACIÓN DE KPI

A través de consultas **SQL** se extrajeron métricas clave para comprender el comportamiento del mercado de viviendas y soportar la toma de decisiones.



PRECIO PROMEDIO DE PROPIEDADES

Cálculo del precio promedio de las viviendas por ciudad y código postal.



ÁREA DE CONSTRUCCIÓN PROMEDIO

Análisis del área de construcción promedio de las propiedades.



ANÁLISIS DE HABITACIONES

Distribución y promedio del número de habitaciones por región.



COMPARATIVO GEOGRÁFICO

Comparación de métricas clave entre ciudades y zonas geográficas.



EVALUACIÓN POR CÓDIGO POSTAL

Evaluación de precios y características por código postal.

jupyterM54 Last Checkpoint: 17 minutes ago

FileEditViewRunKernelSettingsHelp

JupyterLabPython [conda env:base]Anaconda Toolbox

1. Importación de librerías

Se importan las librerías necesarias para el procesamiento, exploración y visualización de datos.

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

2. Configuración de un Data Lake simple

Para esta práctica se utiliza una estructura simple de almacenamiento de datos mediante carpetas locales, simulando las capas de un Data Lake para almacenamiento de datos crudos y procesados.

```
[2]: import os

os.makedirs("data_lake/raw", exist_ok=True)
os.makedirs("data_lake/processed", exist_ok=True)

print("Estructura Data Lake creada correctamente")

Estructura Data Lake creada correctamente
```

3. Configuración de base de datos

Se crea una conexión simple utilizando SQLite como base de datos local para simular un entorno de procesamiento en la nube.

```
[3]: import sqlite3

conexion = sqlite3.connect("housing_cloud.db")

print("Base de datos creada correctamente")

Base de datos creada correctamente
```

4. Importación del archivo Housing

Se importa el dataset Housing utilizando Python y Pandas para comenzar el proceso de exploración y análisis.

```
[4]: housing = pd.read_csv(r"C:\Users\olive\Downloads\Analista de datos M54 - kc_house_data.csv")
```



OBJETIVO

Extraer información clave mediante consultas SQL para generar KPIs accionables.



ENFOQUE

Análisis SQL sobre datos almacenados en SQLite para obtener métricas clave.



BENEFICIO

KPIs confiables que permiten evaluar tendencias, patrones y oportunidades del mercado inmobiliario.



TECNOLOGÍAS CLAVE

SQL, SQLite, Data Lake, Python.



2026



06

VISUALIZACIÓN Y EXPLORACIÓN DE DATOS

Exploración visual de los datos para identificar patrones, relaciones y tendencias clave que apoyan la toma de decisiones estratégicas.



DISTRIBUCIÓN DE PRECIOS

Análisis de la variabilidad del precio de viviendas.



SUPERFICIE vs PRECIO

Relación entre tamaño de propiedad y valor comercial.



COMPARATIVO POR ZONAS

Diferencias de precios entre regiones y ubicaciones.



HABITACIONES Y BAÑOS

Impacto de características estructurales en el precio.



ANÁLISIS GEOGRÁFICO

Distribución espacial del mercado inmobiliario.

M54 Last Checkpoint: 12 minutes ago

File Edit View Run Kernel Settings Help

Trusted

+

✕

📄

📁

▶

⏸

⏹

▶

Code

JupyterLab Python [conda env:base] Anaconda Toolbox

```
[6]: housing.columns

[6]: Index(['id', 'date', 'price', 'bedrooms', 'bathrooms', 'sqft_living',
        'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade',
        'sqft_above', 'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode',
        'lat', 'long', 'sqft_living15', 'sqft_lot15'],
        dtype='object')

[7]: housing = housing.drop_duplicates()

[8]: housing.to_sql(
      "housing",
      conexion,
      if_exists="replace",
      index=False
    )

[8]: 21613
```

7. KPIs del negocio

Se calculan indicadores clave que permiten comprender la magnitud y comportamiento general de las viviendas registradas.

```
[9]: promedio_precio = housing['price'].mean()
    promedio_tamano = housing['sqft_living'].mean()
    promedio_habitaciones = housing['bedrooms'].mean()

    print("Precio promedio: ", promedio_precio)
    print("Tamaño promedio: ", promedio_tamano)
    print("Habitaciones promedio: ", promedio_habitaciones)

Precio promedio: 540088.1417662594
Tamaño promedio: 2079.8997362698374
Habitaciones promedio: 3.37004162309721
```



OBJETIVO

Explorar visualmente los datos para descubrir patrones e insights accionables.



ENFOQUE

Visualización de datos con Python (Pandas, Matplotlib, Seaborn) y análisis exploratorio.



BENEFICIO

Identificación de tendencias, correlaciones y oportunidades para el mercado inmobiliario.



TECNOLOGÍAS CLAVE

Python, Pandas, Matplotlib, Seaborn, SQL, SQLite, Data Lake.



2026



PROYECTO CLOUD ANALYTICS & HOUSING DATA LAKE

Análisis Comercial, ETL, SQL y Visualización de Datos



07

ANÁLISIS VISUAL AVANZADO

Análisis visual avanzado para profundizar en relaciones entre variables, detectar patrones y comprender el comportamiento del mercado inmobiliario.



RELACIONES MULTIVARIABLES

Análisis entre precio, tamaño y características clave.



DISTRIBUCIONES AVANZADAS

Exploración de precios y superficies por segmento.



DETECCIÓN DE OUTLIERS

Identificación de registros atípicos relevantes.



ANÁLISIS POR CLUSTERS

Agrupación de propiedades con comportamiento similar.



KPIs Y TENDENCIAS

Seguimiento visual del comportamiento del mercado.



OBJETIVO

Profundizar en el análisis visual para identificar patrones complejos y relaciones clave.



ENFOQUE

Visualizaciones avanzadas con Python (Seaborn, Matplotlib) y análisis exploratorio.



BENEFICIO

Mejor comprensión del mercado y soporte para decisiones estratégicas basadas en datos.



TECNOLOGÍAS CLAVE

Python, Pandas, Seaborn, Matplotlib, SQL, SQLite, Data Lake.



2026

jupyter

M54 Last Checkpoint: 18 minutes ago



File Edit View Run Kernel Settings Help

Trusted

Code

JupyterLab

Python [conda env:base]

Anaconda Toolbox

11. Consulta SQL

Se ejecuta una consulta SQL simple sobre la base de datos creada.

```
[13]: consulta = pd.read_sql("""
SELECT
    zipcode,
    AVG(price) AS promedioPrecio
FROM housing
GROUP BY zipcode
ORDER BY promedioPrecio DESC
LIMIT 10
""", conexion)
```

```
[13]:
```

	zipcode	promedioPrecio
0	98039	2.160607e+06
1	98004	1.355927e+06
2	98040	1.194230e+06
3	98112	1.095499e+06
4	98102	9.012583e+05
5	98109	8.796236e+05
6	98105	8.628252e+05
7	98006	8.596488e+05
8	98119	8.494480e+05
9	98005	8.101649e+05

12. Conclusión

En esta práctica se implementó una estructura básica de Data Lake y procesamiento de datos utilizando Python. También se creó una base de datos para almacenar información del dataset Housing y se realizaron procesos ETL básicos.

Finalmente, se exploró la información mediante KPIs, consultas y análisis adicionales que permiten comprender mejor el comportamiento de las viviendas y generar información útil para el negocio.

[1]:



08

INSIGHTS Y DASHBOARD EJECUTIVO

Consolidación de insights clave y métricas de negocio en un dashboard ejecutivo para una visión completa del mercado inmobiliario analizado.



VISIÓN GENERAL DEL MERCADO

Resumen ejecutivo de KPIs clave del mercado de viviendas.



PRECIOS Y TENDENCIAS

Análisis de precios promedio, mediana y tendencia por región y código postal.



DISTRIBUCIÓN GEOGRÁFICA

Mapa interactivo con precios promedio por región y volumen de propiedades.




CARACTERÍSTICAS PRINCIPALES

Relación entre área, número de habitaciones, baños y precio de venta.



INSIGHTS CLAVE

Hallazgos accionables que impulsan decisiones estratégicas en el negocio inmobiliario.



OBJETIVO

Transformar datos en insights accionables para el mercado inmobiliario.



DATOS Y PROCESOS

ETL + SQL + Python para integración, procesamiento y análisis de datos.



INSIGHTS GENERADOS

Patrones, tendencias y comportamiento del mercado identificados para una mejor toma de decisiones.



VALOR DE NEGOCIO

Decisiones basadas en datos que impulsan estrategias de inversión y comercialización.



2026



09

HALLAZGOS Y RECOMENDACIONES ESTRATÉGICAS



HALLAZGOS CLAVE



PRECIOS POR UBICACIÓN

Variaciones importantes entre zonas y códigos postales.



RELACIÓN TAMAÑO-PRECIO

Las propiedades más grandes tienden a presentar mayor valor comercial.



PATRONES DEL MERCADO

Diferencias detectadas en comportamiento y distribución inmobiliaria.



INDICADORES ANALÍTICOS

Los KPIs facilitaron la comprensión del mercado.



RECOMENDACIONES ESTRATÉGICAS



Priorizar segmentos y zonas de mayor valor comercial.



Monitorear zonas de alto potencial de crecimiento.



Fortalecer dashboards ejecutivos y seguimiento de KPIs.



Profundizar análisis predictivo y exploratorio para anticipar tendencias.



OBJETIVO

Identificar hallazgos clave del análisis para generar recomendaciones estratégicas de impacto.



ENFOQUE

Análisis de datos y KPIs para comprender patrones y oportunidades del mercado inmobiliario.



BENEFICIO

Insights accionables que impulsan decisiones estratégicas y mejoran la rentabilidad.



VALOR DE NEGOCIO

Mayor eficiencia, reducción de riesgos y aprovechamiento de oportunidades del mercado.



2026



10

MEJORAS Y CONCLUSIÓN



MEJORAS FUTURAS



INCORPORAR MODELOS PREDICTIVOS

Implementar modelos de machine learning para predicción de precios y demanda.



AMPLIAR VARIABLES GEOGRÁFICAS Y TEMPORALES

Incluir más regiones, variables socioeconómicas y series temporales históricas.



AUTOMATIZAR PIPELINE ETL

Optimizar y programar flujos ETL para actualización continua y escalabilidad.



INTEGRAR DASHBOARDS INTERACTIVOS

Desarrollar dashboards avanzados con mayor interactividad y análisis en tiempo real.



CONCLUSIÓN

“

El proyecto permitió implementar un flujo completo de Cloud Analytics combinando ETL, SQL, visualización y análisis de datos para transformar información inmobiliaria en insights estratégicos y apoyar decisiones basadas en datos.

”



OBJETIVO

Consolidar los resultados del análisis y generar recomendaciones estratégicas de alto impacto.



ENFOQUE

Basado en datos, análisis avanzado y visualizaciones que impulsan mejores decisiones.



BENEFICIO

Mayor comprensión del mercado, optimización de recursos y ventaja competitiva.



VALOR DE NEGOCIO

Decisiones más informadas, mayor eficiencia operativa y crecimiento sostenible.

